

Tomada de Decisão em IA

Com certeza! Continuamos a nossa exploração da Inteligência Artificial, focando agora no processo crucial de Tomada de Decisão, especialmente em ambientes onde a incerteza está presente.

(1) Explicação Progressiva dos Fundamentos

Vamos construir nosso conhecimento desde os agentes que tomam decisões simples até os modelos que lidam com decisões complexas sob incerteza.

Nível 1: Agentes de Tomada de Decisão Simples - Agindo com Base em Perceptos ou Modelos Básicos

Em nossa discussão sobre Agentes Inteligentes, vimos diferentes tipos que demonstram capacidades variadas de tomada de decisão:

- **Agentes Reflexivos Simples:** Tomam decisões unicamente com base no percepto atual, seguindo regras diretas "se-então". Sua tomada de decisão é reativa e não considera o histórico ou as consequências futuras.
 - **Exemplo:** Um termostato (se a temperatura $> 20^{\circ}\text{C}$, desligar aquecedor; se a temperatura $< 18^{\circ}\text{C}$, ligar aquecedor). A decisão é baseada apenas na leitura atual do termômetro.
- **Agentes Reflexivos Baseados em Modelo:** Tomam decisões com base no percepto atual e em um *estado interno* que representa um modelo do mundo. Esse modelo permite ao agente ter uma noção do estado do ambiente que não é totalmente visível no percepto imediato. No entanto, a decisão ainda é reativa a esse estado, sem planejamento futuro.
 - **Exemplo:** Um robô aspirador que mantém um mapa parcial da sala (estado interno) para saber onde já limpou. Sua decisão de mover é baseada na leitura atual de sensores e no que ele sabe sobre o mapa, mas ele não planeja a rota ideal para limpar toda a sala.
- **Agentes Baseados em Objetivo (em Ambientes Determinísticos):** Em ambientes onde as ações têm resultados previsíveis (determinísticos), um agente baseado em objetivo toma decisões que o levam a um estado objetivo desejado. Isso frequentemente envolve a utilização de algoritmos de busca (como vimos em Grafos para Busca) para encontrar uma sequência de ações (um plano) que o leve do estado atual ao objetivo.
 - **Exemplo:** Um agente em um jogo de xadrez que busca o estado "xeque-mate" (objetivo) e utiliza algoritmos de busca para encontrar a sequência de movimentos que leva a esse estado.

Nível 2: Agentes de Tomada de Decisão Complexa - Planejamento e Incerteza

Quando o ambiente se torna incerto (resultados das ações não são garantidos) ou quando as decisões precisam ser tomadas sequencialmente ao longo do tempo (cada decisão afeta o futuro), a tomada de decisão se torna mais complexa.

- **Planejamento (em Ambientes Determinísticos ou Parcialmente Observáveis):** Agentes que fazem um plano (uma sequência de ações) para alcançar um objetivo. Isso envolve raciocinar sobre as consequências de múltiplas ações em conjunto. Em ambientes parcialmente observáveis, o agente pode precisar planejar para obter mais informações antes de tomar uma decisão final.
 - **Exemplo:** Um agente robótico em uma fábrica que precisa planejar a sequência de movimentos e manipulações para montar um produto, considerando a ordem das tarefas e os recursos disponíveis.
- **Tomada de Decisão Sequencial sob Incerteza:** Aqui, o agente precisa tomar uma série de decisões ao longo do tempo, onde cada decisão pode influenciar o estado futuro do ambiente e as opções disponíveis, e os resultados das ações são probabilísticos.
 - **Exemplo:** Um agente em um jogo de estratégia onde cada movimento tem um resultado incerto (ex: um ataque pode ter sucesso ou falhar com uma certa probabilidade), e a melhor jogada agora depende de como isso afeta as possibilidades futuras.
- **Processos de Decisão de Markov (MDPs):** Um framework matemático para modelar problemas de tomada de decisão sequencial em ambientes *totalmente observáveis* (o agente sempre sabe o estado atual) e *estocásticos* (os resultados das ações são probabilísticos).
 - **Componentes de um MDP:**
 - **Estados:** Os diferentes estados possíveis do ambiente.
 - **Ações:** As opções que o agente pode escolher em cada estado.
 - **Probabilidades de Transição:** $P(s'|s,a)$ - A probabilidade de transitar para o estado s' após realizar a ação a no estado s .
 - **Recompensas:** $R(s,a,s')$ - Uma recompensa (ou custo) recebida após realizar a ação a no estado s e transitar para o estado s' .
 - **Objetivo:** Encontrar uma *política* (uma regra que diz qual ação tomar em cada estado) que **maximize a recompensa acumulada esperada** ao longo do tempo. Algoritmos como Iteração de Valor e Iteração de Política são usados para resolver MDPs.
- **Processos de Decisão de Markov Parcialmente Observáveis (POMDPs):** Uma extensão dos MDPs para ambientes onde o agente não tem certeza do

estado atual, mas tem observações probabilísticas relacionadas aos estados. Resolver POMDPs é significativamente mais complexo.

Nível 3: Redes de Tomada de Decisão (Diagramas de Influência) - Visualizando e Resolvendo Problemas de Decisão

As Redes de Tomada de Decisão, também conhecidas como Diagramas de Influência, são modelos gráficos que estendem as Redes Bayesianas (que modelam probabilidades e dependências entre variáveis) para incluir decisões e utilidades, fornecendo uma estrutura visual e computacional para modelar e resolver problemas de decisão sob incerteza.

- **O Que são Redes de Tomada de Decisão:** São DAGs (Grafos Acíclicos Direcionados) que representam as relações entre decisões, variáveis aleatórias (eventos incertos) e utilidades em um problema de decisão.
- **Componentes de uma Rede de Tomada de Decisão:**
 - **Nós de Chance (Chance Nodes):** Representam variáveis aleatórias ou eventos incertos (desenhados como círculos ou ovais). Eles possuem probabilidades associadas (frequentemente condicionais a outros nós).
 - **Nós de Decisão (Decision Nodes):** Representam pontos onde o agente ou tomador de decisão precisa escolher uma ação de um conjunto de opções (desenhados como quadrados).
 - **Nós de Utilidade (Utility Nodes):** Representam a utilidade ou o valor do resultado, dependendo do estado de certos nós de chance e decisões tomadas (desenhados como losangos). Eles possuem funções de utilidade associadas.
- **Estrutura:** As setas (arestas) na rede indicam influências ou dependências:
 - Setas entrando em nós de Chance indicam dependências probabilísticas.
 - Setas entrando em nós de Decisão indicam informações que estão disponíveis *antes* da decisão ser tomada.
 - Setas entrando em nós de Utilidade indicam os fatores que afetam a utilidade do resultado (estados de variáveis incertas e decisões tomadas).
- **Resolvendo uma Rede de Tomada de Decisão:** Envolve calcular a utilidade esperada para cada possível sequência de decisões, levando em conta as probabilidades dos eventos incertos e as utilidades dos resultados. O objetivo é encontrar a sequência de decisões que maximize a utilidade esperada. Isso combina inferência probabilística (nas Redes Bayesianas subjacentes) com cálculos de utilidade.
- **Vantagens:** Fornecem uma representação clara e concisa de problemas de decisão complexos, ajudam a identificar as variáveis relevantes e suas relações, permitem a análise estruturada e a resolução de problemas com múltiplas fontes de incerteza.

(2) Resumo dos Principais Pontos

- **Tomada de Decisão em IA:** Seleção de ações para atingir resultados desejados, especialmente sob incerteza.
- **Agentes de Tomada de Decisão Simples:** Baseados em Perceptos (reflexo), Baseados em Modelo (reflexo com estado interno), Baseados em Objetivo (em ambientes determinísticos - usa busca para planejamento).
- **Agentes de Tomada de Decisão Complexa:** Planejamento (sequências de ações em ambientes mais complexos), Tomada de Decisão Sequencial sob Incerteza (série de decisões ao longo do tempo com resultados incertos).
- **Processos de Decisão de Markov (MDPs):** Framework matemático para tomada de decisão sequencial em ambientes totalmente observáveis, estocásticos. Componentes: Estados, Ações, Probabilidades de Transição, Recompensas. Objetivo: Maximizar recompensa esperada (encontrar política).
- **Processos de Decisão de Markov Parcialmente Observáveis (POMDPs):** MDPs para ambientes parcialmente observáveis. Mais complexos.
- **Redes de Tomada de Decisão (Diagramas de Influência):** Modelos gráficos que estendem Redes Bayesianas para incluir decisões e utilidades.
 - **Componentes:** Nós de Chance (incerteza), Nós de Decisão (escolhas), Nós de Utilidade (valor do resultado).
 - **Estrutura:** Setas indicam influências.
 - **Resolução:** Calcular utilidade esperada para cada decisão e maximizar.

(3) Perspectivas e Conexões

- **Teoria da Probabilidade e Utilidade:** Esses campos fornecem os fundamentos matemáticos para a tomada de decisão racional sob incerteza.
- **Machine Learning (Aprendizado por Reforço):** O Aprendizado por Reforço (Reinforcement Learning - RL) é um subcampo do ML que está intrinsecamente ligado aos MDPs. Agentes de RL aprendem a política ótima interagindo com o ambiente e recebendo recompensas, essencialmente resolvendo um MDP (ou POMDP) sem um modelo explícito do ambiente.
- **Sistemas de Suporte à Decisão (SSD):** Redes de Tomada de Decisão são frequentemente utilizadas em SSDs para modelar problemas complexos e ajudar os tomadores de decisão a avaliar diferentes opções.
- **Economia e Finanças:** A Teoria da Decisão e conceitos de utilidade são amplamente aplicados em economia e finanças para modelar o comportamento de agentes racionais e avaliar investimentos sob risco.

- **Robótica e Controle:** Robôs e sistemas de controle autônomo utilizam modelos de decisão (como MDPs) para planejar suas ações e navegar em ambientes incertos.
- **Inteligência Artificial em Jogos:** A IA em jogos frequentemente utiliza algoritmos de tomada de decisão para controlar o comportamento de personagens não jogáveis em ambientes dinâmicos e incertos.

(4) Materiais Complementares Confiáveis e Ricos em Conteúdo

- **Livros:**
 - "Artificial Intelligence: A Modern Approach" de Stuart Russell e Peter Norvig (Capítulos sobre Planejamento, Tomada de Decisão sob Incerteza, MDPs, Redes de Decisão).
 - "Reinforcement Learning: An Introduction" de Richard S. Sutton e Andrew G. Barto (para aprofundar em MDPs e RL).
 - "Probabilistic Graphical Models: Principles and Techniques" de Daphne Koller e Nir Friedman (seções sobre Redes de Decisão).
- **Cursos Online:**
 - Cursos sobre IA, Planejamento, Machine Learning (foco em RL) e Modelos Gráficos Probabilísticos em plataformas como Coursera, edX, Udacity.
- **Websites e Tutoriais:**
 - Tutoriais online sobre MDPs, Redes de Decisão e Aprendizado por Reforço.
 - Vídeos explicativos sobre esses tópicos.

(5) Exemplos Práticos

- **Agente Baseado em Objetivo (Navegação Simples):** Um robô que precisa ir do ponto A ao ponto B em um labirinto conhecido. Ele usa um algoritmo de busca (ex: A*) para encontrar a sequência de movimentos (o plano) que o leva ao objetivo.
- **MDP (Controle de Inventário Automatizado):** Um agente precisa decidir quanto estoque de um produto pedir a cada semana para maximizar o lucro ao longo do tempo. Os estados são os níveis de estoque, as ações são as quantidades a pedir. A demanda é incerta (probabilística). As recompensas são baseadas nas vendas e nos custos de estoque. O objetivo é encontrar a política de pedido ótima para cada nível de estoque.
- **Rede de Tomada de Decisão (Decisão de Investimento):**
 - **Nó de Decisão:** Investir (sim/não).
 - **Nós de Chance:**
 - Condição do Mercado (Alto/Baixo - probabilidade estimada).

- Desempenho da Empresa (Bom/Ruim - probabilidade dependendo da Condição do Mercado).
- **Nó de Utilidade:** Lucro (depende da Decisão, Condição do Mercado e Desempenho da Empresa).
- **Resolução:** Calcular a utilidade esperada para "Investir Sim" e "Investir Não", considerando as probabilidades e os possíveis lucros em cada cenário, e escolher a decisão com a maior utilidade esperada.

Metáforas e Pequenas Histórias para Memorização

- **O Navegador no Mar Incerto (Tomada de Decisão sob Incerteza):** Tomar decisões sob incerteza é como um navegador em um mar com neblina e correntes imprevisíveis. Ele precisa decidir qual rota tomar (ação) sem ter certeza do que vai encontrar (resultado incerto), mas usando o que sabe sobre as probabilidades das correntes e o valor de chegar a diferentes portos (utilidade).
- **O Planejador Mestre (Agente de Tomada de Decisão Complexa):** Um agente de tomada de decisão complexa é como um mestre planejador que não apenas reage ao que vê, mas olha para o futuro, considera diferentes caminhos possíveis (sequências de ações), calcula as chances de sucesso em cada caminho (probabilidade) e avalia o quão bom seria o resultado (utilidade) antes de escolher o melhor caminho a seguir.
- **O Jogo da Vida com Recompensas (MDP):** A vida do agente em um MDP é como um jogo onde em cada rodada (estado) ele escolhe uma ação, e o resultado é sorteado (probabilístico), levando-o para uma nova rodada (novo estado) com uma pontuação (recompensa). O agente aprende a jogar de forma a acumular o máximo de pontos possível ao longo do jogo.
- **O Mapa com Escolhas e Valores (Rede de Tomada de Decisão):** Uma rede de tomada de decisão é como um mapa especial. Ele não apenas mostra os locais (estados) e os caminhos (ações), mas também indica onde há cruzações onde você tem que escolher um caminho (nós de decisão), onde há eventos aleatórios que podem te levar para lugares diferentes (nós de chance com probabilidades) e quão "bom" ou "ruim" é chegar a cada local (nós de utilidade). O objetivo é traçar a melhor rota, considerando as chances e o quão bons são os destinos finais.